

RadarMind-DriveLM

六视角 Graph-VLM 技术演进报告

从零样本基模、垂域 SFT、DPO、Mixture of LoRA、
Trajectory RL 到 Graph 专家路由的完整可复现链路

报告版本: v2.0 (覆盖项目 v0.31-v0.44)

项目作者: 张宗元

更新日期: 2026-08-18

发布仓库: [radarmind-drive_{lm}](#)

当前基线: v0.43 Graph anchor + MoL downstream

本报告只使用可由本地 JSON、日志、checkpoint 与代码复核的结果。
3,355 条指标来自 scene-isolated local dev; 语义裁判为 DeepSeek-V4-Flash 代理,
不是官方隐藏服务器的 ChatGPT 分数。

摘要

本报告总结 RadarMind-DriveLM 从最初数据复现到完整 Graph-VLM Agent 的技术演进。项目以 DriveLM-nuScenes v1.1 为数据基础，将单帧六路同步相机图像组织为 26,095 条训练 QA 与 3,355 条场景隔离开发集 QA，覆盖 Perception、Prediction、Planning、Behavior 四类任务。模型主线由 Qwen2.5-VL-7B-Instruct 出发，依次完成纯交叉熵 LoRA SFT、任务均衡且带 CE anchor 的保守 DPO、四任务 Mixture of LoRA (MoL)、Planning trajectory GRPO/GSPO、四阶段 Graph trajectory SFT，以及受 InternVL4Drive 启发的固定专家路由。

零样本基模的本地 DriveLM-DS Final 为 0.257961；六相机垂域 CE-SFT 提升到 0.594636；保守 DPO 提升到 0.596356；四专家 MoL 提升到 0.608245。GRPO/GSPO 在 Planning 子协议上改善 trajectory reward，但接回完整系统后未超过 MoL。Graph-SFT 显著改善坐标 grounding，却因 teacher forcing 与 predicted-context 的暴露偏差未通过 same-ID 晋级门槛。最终系统把 Graph-A 只用于每帧第一个重要对象 anchor，把 MoL-700 用于其余 2,888 条下游 QA，在 3,355 条完整开发集上取得 0.612293；严格 1,848-ID 共同子集 Final 同样由 0.609563 提升到 0.610557。因此 v0.43 是当前本地全系统基线。

报告同时保留具有方法论价值的负实验：增加视觉 token、标准 DPO、grounding DPO、全系统 GRPO/GSPO、Graph+anchor 混合训练、显式六相机拓扑提示和 image-only bbox 辅助监督均未通过冻结晋级门槛。这些结果共同说明：DriveLM 的主要困难不是单一语言指标，而是 graph gating、对象召回、任务梯度冲突和上游误差传播；可靠模型选择必须结合完整 Final、predicted-context rollout 与 same-ID 公平审计。

目录

1 项目目标与最终系统	3
1.1 问题定义	3
1.2 当前部署结构	3
2 数据、拆分与训练输入	3
2.1 数据来源	3
2.2 场景级隔离拆分	4
2.3 JSONL 与监督边界	5
3 统一评测协议	5
3.1 为什么不能只看 Token-F1	5
3.2 本地 DriveLM-DS	5
3.3 Graph gating 与 same-ID 公平审计	5
3.4 Predicted-context rollout	5
4 技术演进与理论依据	6
4.1 阶段 0：零样本基模	6
4.2 阶段 1：六相机纯 CE-LoRA SFT	6
4.3 阶段 2：CE 锚定的保守 DPO	6

4.4	阶段 3: Mixture of LoRA 专家分解	6
4.5	阶段 4: Planning trajectory GRPO 与 GSPO	7
4.6	阶段 5: 四阶段 Graph trajectory SFT	7
4.7	阶段 6: 受 InternVL4Drive 启发的固定专家路由	7
4.8	阶段 7: 空间提示与 bbox 辅助负实验	8
5	统一性能演进	8
5.1	累计增益	8
5.2	当前基线完整指标	9
6	晋级制度与实验可信度	9
6.1	冻结门槛	9
6.2	外部 Judge 与缓存边界	9
7	从正负实验得到的理论结论	9
8	工程复现与产物	10
8.1	核心目录	10
8.2	关键复现命令	10
8.3	可视化展示	11
9	局限性与下一步	11
10	结论	12
	参考资料	12
A	版本与决策索引	12
B	v0.44 最新负实验明细	13
C	报告再生成	13

1 项目目标与最终系统

1.1 问题定义

DriveLM 将自动驾驶推理表示为 Graph Visual Question Answering (Graph-VQA)。模型不仅需要描述场景，还要围绕关键对象完成四类任务：

- **Perception**：识别影响驾驶决策的车辆、行人、骑行者和交通元素，并判断对象状态；
- **Prediction**：推断对象类别、运动趋势与自车未来位置需要关注的对象；
- **Planning**：生成候选动作、碰撞风险动作与安全动作；
- **Behavior**：从选项中判断自车速度与转向组合。

项目目标不是把每条 QA 独立做成普通图文问答，而是构建能够沿 Perception → Prediction → Planning → Behavior 传播工作记忆的感知决策 Agent，并用接近官方结构的指标验证其完整系统性能。

1.2 当前部署结构

最终 v0.43 没有同时加载四个完整 VLM。系统共享一个 7B 基座，在推理时挂载任务适配器，并使用固定、无答案依赖的路由：每帧 `qa_index=0` 的 important-object anchor 由 Graph-A 生成，其余 QA 由 MoL-700 的任务专家生成。




图 1: 当前 v0.43 系统：共享基座、固定 anchor 专家与任务 LoRA 专家。路由规则不读取参考答案、候选文本或 dev 得分。

最终结论：完整 3,355-QA Final 为 **0.612293**；相对 MoL-700 的 0.608245 绝对提升 0.004048。严格 1,848-ID 共同子集 Final 仍提升 0.000993，因此不是 graph gating 改变题目集合造成的虚假增益。

2 数据、拆分与训练输入

2.1 数据来源

训练标注来自 DriveLM-nuScenes v1.1，视觉输入为同一关键帧的六路相机：

CAM_FRONT、CAM_FRONT_LEFT、CAM_FRONT_RIGHT；
CAM_BACK、CAM_BACK_LEFT、CAM_BACK_RIGHT。

项目保留六图独立输入，不把六相机强制拼成单张 mosaic。这样可避免额外缩放、视角边界和单图动态切片造成的信息损失。



图 2: 同一关键帧的六路同步图像。训练和推理中的相机顺序固定。

2.2 场景级隔离拆分

对 scene token 计算 SHA-256 哈希桶:

$$b(s) = \frac{\text{int}(\text{SHA256}(s)_{0:8}, 16)}{2^{32} - 1}.$$

当 $b(s) < 0.1$ 时整个场景进入 dev, 否则进入 train。同一约 20 秒场景的相邻关键帧不会跨越训练和开发集。

表 1: 当前主线数据规模。

划分	场景数	Frame trajectory	QA 数	用途
Train	619	3,605	26,095	SFT / DPO / MoL / Graph
Local dev	77	467	3,355	本地生成、筛选与公平审计
Official val	149	–	15,480	无答案提交集




图 3: 训练、开发和官方 val 中四类任务的数量分布。

2.3 JSONL 与监督边界

每条独立 QA 样本包含 scene ID、frame ID、QA index、任务类型、六图路径和 system/user/assistant 消息。CE-SFT 只监督 assistant token，图像、system 和 user token 的 label 为 -100：

$$\mathcal{L}_{\text{CE}} = - \sum_{t \in \text{assistant}} \log p_{\theta}(y_t \mid I_{1:6}, q, y_{<t}).$$

Graph-SFT 将同一帧的全部 QA 打包为多轮 trajectory；六张图只在首节点输入，后续节点读取上游 assistant 消息作为显式工作记忆。

3 统一评测协议

3.1 为什么不能只看 Token-F1

DriveLM 同时包含短分类答案、自由文本规划、对象坐标和图依赖。单一 lexical 指标无法反映：对象识别错误是否导致后续问题被 gating、同义规划是否语义正确、坐标是否匹配，以及模型是否只在较容易的有效子集上得分。因此主线同时报告离线 lexical 指标、结构指标、语义裁判和完整 Final。

3.2 本地 DriveLM-DS

本地 evaluator 沿用公开 challenge 的指标结构：

$$S_{\text{Final}} = 0.4S_{\text{semantic}} + 0.2S_{\text{language}} + 0.2S_{\text{match}} + 0.2S_{\text{accuracy}}.$$

其中 semantic 使用 DeepSeek-V4-Flash、temperature 0，作为官方 ChatGPT Score 的本地代理；Language 由 BLEU-1-4、ROUGE-L 和 CIDEr 合成；Match 衡量重要对象与坐标结构；Accuracy 处理分类式问题。所有可比较候选要求 3,355/3,355 coverage 和 Judge completion 100%。

3.3 Graph gating 与 same-ID 公平审计

每帧首个 important-object 回答决定哪些下游 QA 满足坐标 gating。两个模型可能拥有不同的 eligible 集合，直接比较 Full Final 会把“模型能力变化”和“题目集合变化”混在一起。项目因此固定执行：

$$\mathcal{I}_{\text{pair}} = \mathcal{I}_{\text{baseline}} \cap \mathcal{I}_{\text{candidate}}.$$

双方只在 $\mathcal{I}_{\text{pair}}$ 上重新计算指标，并要求 Final 严格提高，Planning、MC 与 coordinate F1 不超过预注册回退阈值。

3.4 Predicted-context rollout

Teacher-forced dev NLL 只回答“给定正确上游答案时，模型能否预测当前答案”。真实 Agent 没有 gold context，因此最终 Graph 评测必须执行：

$$\hat{y}_1 = f(I, q_1), \quad \hat{y}_t = f(I, q_{1:t}, \hat{y}_{1:t-1}).$$

即把模型自己的 Perception/Prediction 输出继续输入 Planning/Behavior。该协议显式测量上游错误传播与 exposure mismatch；dev NLL 仅用于低成本 checkpoint screening，不用于最终晋级。

4 技术演进与理论依据

4.1 阶段 0：零样本基模

Qwen2.5-VL-7B-Instruct 原生支持多图，但未经 DriveLM 模板、对象 ID、坐标和规划语言适配。零样本 Final 仅 0.257961，说明通用视觉语言能力不能直接替代垂域格式与决策知识。该结果为后续所有改进提供冻结起点。

4.2 阶段 1：六相机纯 CE-LoRA SFT

首个稳定 7B 主线采用单帧六图、assistant-token-only CE 和 LoRA。LoRA rank 8、 $\alpha = 16$ 、dropout 0.05，目标模块包括注意力投影与 MLP 投影；adapter 包含视觉和语言两部分参数。在当前 7B 配置中，可训练参数 23,794,688，占 8,315,961,344 总参数的约 0.286%。

纯 CE 的理论作用是最大化垂域答案似然，不把 dev Final、judge 或手写 metric 权重混进初始表示学习。B10 将 Final 从 0.257961 提升到 0.594636，是整个项目最大的单阶段增益，也验证“先建立强 CE 基线，再进行偏好或 RL 优化”的路线。

同阶段的高视觉预算 B11 反而下降到 0.580881。更多视觉 token 增加了计算量，却没有自动改善对象召回，说明瓶颈不仅是分辨率，还包括监督对齐、任务干扰与坐标格式。

4.3 阶段 2：CE 锚定的保守 DPO

标准 DPO 使用 7,149 组候选偏好对，优化 chosen 相对 rejected 的优势：

$$\mathcal{L}_{\text{DPO}} = -\log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y^+ | x)}{\pi_{\text{ref}}(y^+ | x)} - \log \frac{\pi_{\theta}(y^- | x)}{\pi_{\text{ref}}(y^- | x)} \right] \right).$$

标准 DPO-100 虽提高部分 lexical 与 MC 指标，但 Planning/judge 回退，Final 为 0.594300。问题表现为偏好分布不均和更新过强，而非 adapter 容量不足。

保守 DPO 将四任务偏好均衡，使用较小 $\beta = 0.05$ ，并加入 chosen-answer CE anchor：

$$\mathcal{L} = \mathcal{L}_{\text{DPO}} + \lambda \mathcal{L}_{\text{CE}}(y^+), \quad \lambda = 0.1.$$

CE anchor 相当于对原语言建模能力施加软约束，降低 preference over-optimization。checkpoint-75 的 Final 达到 0.596356；1,807-ID same-ID Final 同样提高 0.001056，因此正式晋级。

4.4 阶段 3：Mixture of LoRA 专家分解

单个 adapter 同时优化四类任务时，短分类、长规划与坐标 grounding 的梯度可能方向冲突。MoL 使用一个共享 7B 基座和四个任务 LoRA：

$$e = r(q) \in \{P, Pr, Pl, B\}, \quad h' = h + \Delta W_e h.$$

路由 $r(q)$ 只读取已知任务类型，而不是候选答案或 dev 分数，因此可部署且无答案依赖。每个专家仍用普通 CE 训练；改进来自参数子空间解耦，而不是将最终评测指标写入 loss。

自适应 controller 每 100 step 评估 Token-F1，同时设置 Planning、MC、anchor F1 安全门槛；step 800/900 连续未超过 step 700 的最小增益，触发 patience=2 并回滚。MoL-700 将 Final 提升到 0.608245，same-ID Final 提升 0.013886，是 SFT 后最重要的结构改进。

4.5 阶段 4: Planning trajectory GRPO 与 GSPO

项目把冻结的 Perception/Prediction 结果组织为 Planning trajectory 上下文，对 Planning 专家进行组相对策略优化。确定性奖励为：

$$R = 0.40F_{1,\text{token}} + 0.20R_L + 0.25F_{1,\text{action}} + 0.05\text{EM} + 0.05V_{\text{ground}} + 0.05V_{\text{format}}.$$

GRPO 与 GSPO 共享数据、候选数、seed、reward 和训练预算，只改变 policy loss 聚合。GSPO-90 在 Planning 子协议上取得最高 reward 61.2600，优于 MoL control 60.8118 和 GRPO-70 61.1674。

然而接回四任务系统后，GRPO/GSPO Final 分别为 0.606702/0.606640，均低于 MoL-700。理论原因是局部 reward 优化与 graph-eligible Final 不完全一致；一个策略可以改善全体 Planning trajectory，却在官方 gating 后的 Planning 子集上退化。该实验说明 RL 的 reward 必须与最终部署分布和系统级晋级门槛联合验证。

4.6 阶段 5: 四阶段 Graph trajectory SFT

Graph-SFT 将同一帧的全部节点打包为一条因果对话，所有 assistant span 计算 CE。下游 token loss 通过共享 attention 更新模型参数，使模型学习跨任务上下文；但离散上游文本本身不可微，不能把 Planning 的 token loss 直接“反传成正确的 Perception 答案”。

Graph-A 将坐标 grounding 与 Match 显著提高，candidate-dependent Full Final 达到 0.609998；但在严格 1,848-ID 交集上 Final 下降 0.003428，Planning 与 MC 也下降，因此未晋级。核心问题是 teacher forcing：训练时下游看到 gold 上游答案，部署时看到模型预测，形成 exposure mismatch。Graph+CE-anchor 混合版本也未修复这一问题。

4.7 阶段 6: 受 InternVL4Drive 启发的固定专家路由

InternVL4Drive 的可迁移洞见不是必须更换为 25.5B InternVL，而是利用互补模型：Grounding 强的模型负责感知瓶颈，推理强的模型负责下游。项目冻结路由：

```
if qa_index == 0:
    answer = Graph_A(frame_anchor)
else:
    answer = MoL_700(task_expert)
```

路由只使用输入侧节点位置，不读取答案、reference、置信度或 dev 分数。Graph-A 负责 467 条 frame anchor；MoL-700 负责 2,888 条下游 QA。该组合把“坐标召回”和“规划语言”分配给各自优势专家，避免在同一个 adapter 内折中。

完整 Final 从 0.608245 提高到 0.612293；common 1,848-ID Final 从 0.609563 提高到 0.610557，全部 paired gates 通过。网络禁用的 cache-only Judge 完成 791/791 命中，保证本轮没有新增外发 payload。

4.8 阶段 7：空间提示与 bbox 辅助负实验

为验证 InternVL 的其他思路，v0.44 保持六张独立图输入，测试：

- 1. **显式相机拓扑**：在 system prompt 中声明前、后、左右视角及相机内坐标系；
- 2. **image-only bbox auxiliary**：训练时只输入原始六图，目标只输出相机名和归一化 bbox；不输入真实框、中心点、类别、状态或描述。视觉 LoRA 确实接收梯度。

显式拓扑模型的 EM 与部分坐标指标略升，但 Token-F1、MC 和 eligible 数下降；接入 “anchor+MoL” 后仍略低于 v0.43。bbox 辅助模型的 anchor F1 降到 12.77%，eligible 降到 1,883，Planning Token-F1 降到 57.57%。可能原因包括辅助检测目标与 DriveLM center-point/graph 目标不一致、有限 LoRA 容量下的梯度干扰，以及 “所有重要对象框” 对最终语言规划并非充分统计量。两者均作为负实验保存，不调用额外语义 Judge，也不替换主线。

5 统一性能演进

表 2: 3,355-QA 本地完整系统性能。Final 均为同一 DriveLM-DS 代理结构；† 表示最终晋级。

模型阶段	EM	Token-F1	ROUGE-L	MC	Judge/100	Final	结论
7B zero-shot	13.71	24.23	21.74	51.69	36.83	0.257961	control
CE-LoRA B10	43.46	73.00	71.08	83.82	70.63	0.594636	†
Standard DPO-100	43.55	73.17	71.22	84.27	69.75	0.594300	未晋级
Conservative DPO-75	43.58	73.12	71.20	84.16	70.86	0.596356	†
Grounding DPO-50	–	–	–	–	69.73	0.592092	未晋级
MoL-700	43.99	74.53	72.41	84.49	72.48	0.608245	†
GRPO-70 full system	43.55	74.00	71.90	84.49	72.09	0.606702	未晋级
GSPO-90 full system	43.79	74.02	71.94	84.49	72.08	0.606640	未晋级
Graph-A CE-600	43.04	73.04	71.00	83.71	71.30	0.609998	same-ID 拒绝
Graph+anchor-600	42.62	72.56	70.55	83.48	70.70	0.605430	未晋级
Graph anchor + MoL	43.99	74.48	72.38	84.49	73.02	0.612293	当前基线

5.1 累计增益

- zero-shot → CE-SFT：Final 绝对提升 0.336675，相对提升约 130.52%；
- CE-SFT → conservative DPO：提升 0.001721；
- conservative DPO → MoL：提升 0.011889；
- MoL → fixed anchor ensemble：提升 0.004048；
- zero-shot → 当前系统：Final 从 0.257961 提升到 0.612293，绝对提升 0.354332。

5.2 当前基线完整指标

表 3: v0.43 完整 3,355-QA 官方风格本地指标。

指标	数值	指标	数值
Coverage	3,355/3,355	Graph eligible	1,927
Accuracy	0.813154	Semantic Judge	73.0197
BLEU-1	0.789634	BLEU-2	0.724770
BLEU-3	0.665099	BLEU-4	0.607520
ROUGE-L	0.724571	CIDEr	0.198875
Match /100	30.7513	Final	0.612293

6 晋级制度与实验可信度

6.1 冻结门槛

每个阶段在查看语义 Final 前先完成 lexical/structural screening，冻结候选选择规则。完整晋级要求：

1. 3,355/3,355 coverage，空答案与重复 ID 为 0；
2. 语义 Judge complete 100%；
3. Full Final 严格提高；
4. same-ID Final 严格提高；
5. Planning、MC、coordinate F1 不越过预注册回退阈值；
6. 训练数据不包含 dev/hidden-val 答案，路由不使用 reference 或候选得分。

这套门槛解释了为什么 Graph-A 的 raw Final 0.609998 高于 MoL 0.608245，却没有直接晋级：它在共同 1,848-ID 上退化。相反，v0.43 在 full 与 paired 两种口径上均提高，因此可以成为新基线。

6.2 外部 Judge 与缓存边界

官方 ChatGPT evaluator 在本地不可用，项目使用 DeepSeek-V4-Flash 作为语义代理；其数值不能与官方 leaderboard 直接等同。Judge 请求以 model、base URL、prompt version、candidate、reference 和 kind 形成哈希缓存键。cache-only evaluator 以 SQLite read-only 模式工作，任一 miss 立即失败，防止未授权数据发送。

7 从正负实验得到的理论结论

1. **垂域 SFT 是必要条件**。通用 VLM 不熟悉 DriveLM 对象 ID、坐标、回答模板和决策语言；纯 CE 已解决大部分 domain gap。
2. **偏好优化需要保留语言锚**。标准 DPO 容易过优化偏好边界；任务均衡与 chosen CE anchor 能降低灾难性漂移。
3. **任务分解比单一共享 adapter 更有效**。MoL 的主要收益来自减少四任务之间的梯度冲突，且 hard router 比答案依赖 gate 更容易审计。
4. **局部 reward 提升不代表全系统提升**。GRPO/GSPO 改善 Planning trajectory，但 graph gating 后的部署分布不同；系统级 Final 必须作为最终门控。

5. **Graph 结构既是能力来源也是评测陷阱。**联合 trajectory 能改善 grounding, 但 teacher forcing 会掩盖上游错误传播; 必须使用 predicted-context 与 same-ID。
6. **专家组合可优于继续训练。**v0.43 没有新增模型参数, 只通过固定节点级路由组合 Graph-A 与 MoL 的互补优势, 取得当前最大后期增益。
7. **更多视觉监督并不自动更好。**提高 token、显式相机拓扑和 bbox 辅助均未晋级; 辅助目标只有在与最终 graph/center-point 目标和采样分布一致时才可能有效。

8 工程复现与产物

8.1 核心目录

reproduction/qwen_vl_v036/	# 7B pure CE SFT
reproduction/qwen_vl_v037b/	# conservative DPO + CE anchor
reproduction/qwen_vl_v039_mol/	# four LoRA experts + controller
reproduction/qwen_vl_v040_trajectory_rl/	# GRPO / GSP0
reproduction/qwen_vl_v042_graph/	# Graph-SFT + rollout
reproduction/qwen_vl_v043_internvl_transfer/	# fixed expert routing
reproduction/qwen_vl_v044_spatial_bbox/	# topology/bbox negative ablation
reproduction/drivelm_ds_eval/	# official-style local evaluator
results/leaderboard/	# complete machine-readable table

8.2 关键复现命令

```
# Build scene-isolated six-camera data
python reproduction/qwen_vl/build_dataset.py \
  --train-json /mnt/data/zzy/drivelm/data/QA_dataset_nus/vl_1_train_nus.json \
  --val-json /mnt/data/zzy/drivelm/data/QA_dataset_nus/vl_1_val_nus_q_only.json \
  --output-dir /mnt/data/zzy/drivelm/reproduction/qwen_vl \
  --seed 42 --dev-ratio 0.1

# Build the promoted v0.43 fixed router output
python reproduction/qwen_vl_v043_internvl_transfer/build_fixed_ensemble.py \
  --references-jsonl /mnt/data/zzy/drivelm/reproduction/qwen_vl_stage2_ablation_v1/
  qwen_v033_c00_dev.jsonl \
  --baseline-json /mnt/data/zzy/drivelm/reproduction/qwen_vl_v039_mol/sweep/checkpoint
  -700/mol_dev_predictions.json \
  --grounding-json /mnt/data/zzy/drivelm/reproduction/qwen_vl_v042_graph/
  rollout_checkpoint600/graph_dev_predictions.json \
  --mode anchor --output-json ensemble_predictions.json \
  --report-json build_report.json

# Network-disabled semantic evaluation from an existing cache
python reproduction/drivelm_ds_eval/evaluate_cache_only.py \
  --references-jsonl qwen_v033_c00_dev.jsonl \
  --predictions-json ensemble_predictions.json \
  --output-json drivelm_ds.json --cache-file deepseek_judge.sqlite
```

8.3 可视化展示

项目生成连续驾驶视频：画面正常播放，在关键问题处冻结并弹出模型问答，再继续播放。视频用于展示 Agent 交互和答案格式，不替代 dev 定量指标；画面中的标注框均明确标识来源。



连续播放 → 关键帧冻结 → 问题 → 真实模型回答 → 恢复时间线

图 4: 两类昼夜场景的连续 DriveLM 问答展示。定性视频与定量 dev 评测严格分离。

9 局限性与下一步

- 当前 Final 是 local dev + DeepSeek proxy, 不是官方 hidden-server ChatGPT 分数;
- 主要实验为单 seed, 尚未通过多随机种子给出置信区间;
- 单帧六相机难以可靠恢复真实速度、加速度和转向变化;

- Graph-SFT 仍有 teacher-forcing exposure mismatch;
- 当前主线是纯视觉 DriveLM, 尚未把 radar token 纳入同一受控榜单;
- v0.43 依赖多个 LoRA adapter 的固定路由, 服务端需要 adapter 缓存或高效切换。

推荐后续优先级:

1. 在官方 val/test 服务器验证 v0.43, 建立 local proxy 与官方分数的相关性;
2. 对 Graph-SFT 使用 scheduled sampling 或 DAgger, 把部分 gold context 替换为冻结模型预测;
3. 直接优化 graph-eligible Planning 或使用双门控 reward, 避免 RL 子协议与全系统错位;
4. 对当前晋级链至少补充 3 个 seed, 并报告 paired bootstrap 置信区间;
5. 在不改变六相机基线的前提下增加 radar encoder, 严格比较 camera-only、radar-only 与 fusion;
6. 将最终 Planning 输出映射为结构化动作, 并在 CARLA safety shield 下进行闭环验证。

10 结论

RadarMind-DriveLM 已从“能运行的六相机 VQA 复现”演进为具有数据治理、分阶段训练、Graph rollout、系统级评测和公平晋级机制的自动驾驶 VLM Agent。最重要的工程结果不是某个单点算法, 而是形成了可证伪的实验闭环: CE 建立垂域能力, 保守 DPO 校准偏好, MoL 缓解任务冲突, RL 检查序列级优化, Graph-SFT 暴露上游误差传播, 最终用固定专家路由组合互补能力。

当前 v0.43 在本地完整协议上达到 **0.612293**, 相比零样本基模提升 0.354332; 其 same-ID 增益证明提升并非来自 gating 子集变化。空间提示和 bbox 辅助的负结果也被完整保留, 为后续 scheduled sampling、多模态雷达融合与 CARLA 闭环提供了明确边界。

参考资料

1. Sima, C. et al. *DriveLM: Driving with Graph Visual Question Answering*. ECCV 2024; arXiv:2312.14150.
2. Bai, S. et al. *Qwen2.5-VL Technical Report*. arXiv:2502.13923, 2025.
3. Caesar, H. et al. *nuScenes: A Multimodal Dataset for Autonomous Driving*. CVPR 2020.
4. Hu, E. J. et al. *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR 2022.
5. Rafailov, R. et al. *Direct Preference Optimization: Your Language Model is Secretly a Reward Model*. NeurIPS 2023.
6. Shao, Z. et al. *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models*. arXiv:2402.03300, 2024 (GRPO) .
7. Li, J., Li, Z., Lu, T. *Driving with InternVL*. CVPR 2024 Autonomous Grand Challenge technical report.
8. OpenGVLab. *InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks*. CVPR 2024.

A 版本与决策索引

版本	方法	主要证据	决策
v0.31	3B 初始复现	打通数据、LoRA、dev、官方 val 输出	历史起点
v0.36	7B CE-LoRA	Final 0.594636	晋级
v0.37A	Standard DPO	Final 0.594300	拒绝
v0.37B	Conservative DPO	Full 与 same-ID 均提高	晋级
v0.38A	Grounding DPO	Final 0.592092	拒绝
v0.39B	Four-expert MoL	Final 0.608245, controller 选 step 700	晋级
v0.40	GRPO / GSPO	Planning 子协议提高, 全系统下降	拒绝
v0.42A/B	Graph trajectory SFT	grounding 提高, same-ID 下降	拒绝
v0.43	Graph anchor + MoL	Full 0.612293; paired +0.000993	晋级
v0.44	topology / bbox auxiliary	局部改善或整体退化	拒绝

B v0.44 最新负实验明细

表 5: 不调用外部 Judge 的 3,355-QA predicted-context 离线结果。

模型	EM	Token-F1	ROUGE-L	Planning F1	MC
Graph-A	43.0402	73.0446	71.0026	58.3614	83.7079
显式相机拓扑	43.5768	73.0125	71.0570	58.3903	83.4831
相机拓扑 +bbox	43.0402	72.6065	70.6764	57.5701	83.3708

显式拓扑作为 v0.43 anchor 替代时, EM 和 MC 与当前系统相同, 但 Token-F1 从 74.4813% 降到 74.4793%, ROUGE-L 从 72.3789% 降到 72.3573%, eligible 从 1,927 降到 1,910; 因此无需消耗额外 API Judge 即可在冻结 pre-gate 淘汰。

C 报告再生成

```
cd /home/zhangzongyuan/Myproject/publish/radar-mind-drive-lm/reports/  
  drivelm_reproduction_v1  
xelatex -interaction=nonstopmode -halt-on-error drivelm_reproduction_technical_report.  
tex  
xelatex -interaction=nonstopmode -halt-on-error drivelm_reproduction_technical_report.  
tex
```